


資料管理與分析

一、學習資料處理動機

在使用統計方法分析資料之前通常必須針對資料做適當處理。例如您可能想分析乳癌病人其 Conservative Surgery 和 Total Mastectomy 其存活之差別，有關的變項包括年齡、診斷日期、死亡日期等，而如果這些資料均在病歷或死亡診斷書上，您如何將資料鍵入電腦進而使用存活分析來比較兩組存活曲線，這是一個臨床流行病學例子，在預防醫學領域中諸如此類資料相當多，其來源可能是問卷、病歷、檢驗報告、健保申報、死亡診斷等，因此必須學會資料處理(Data Management)，一般而言其程序如下：



問卷格式示範

一、基本資料

病人姓名：_____ 1-10

出生年月日：_____年_____月_____日
11-12 13-14 15-16

二、診斷時間：_____年_____月_____日
17-18 19-20 21-22

三、治療方式

- (1)None (2) Quadrantectomy (3)Sub-mastectomy
(4)Total mastectomy without axillary dissection
(5)Total mastectomy with axillary dissection
(6)Radical mastectomy (7)Needle biopsy

四、死亡時間：_____年_____月_____日
24-25 26-27 28-29

五、死亡原因：(1)not record (2)BrCa primary
(3)BrCa present (4)Other Causes

□□□□□□□□□□

1-10

□□ □□ □□

11-12 13-14 15-16

□□ □□ □□

17-18 19-20 21-22

□

23

□□ □□ □□

24-25 26-27 28-29

□

30

二、資料型態

(一) 常見建檔軟體

1. Excel(*.xls), Lotus3-4(*.wk3 or *.wk4)等以 Spreadsheet 方式建檔
2. DBASE file(*.dbf)或 Acces(*.mab)
3. ASCII 文字檔
4. SAS & SPSS
5. Word & Notepad (不建議使用)

上述建檔軟體除了 ASCII 文字檔，其他方式建檔通常可以直接使用 SAS Import 方式直接載入，不用定義變項(見下文)。

(二) ASCII 格式(Format)：

以一般 ASCII 格式而言，一般資料分為 2 種型式

1. 固定格式(Fixed Format)

資料中每個變項長度是固定，這些長度必須在讀取資料、定義變項時加以宣告。

2. 自由格式(Free Format)

資料中每個變項長度並沒有固定，而變項與變項之間以空白、逗號(,)、分號(;) 等隔開。

例 1：以乳癌資料為例，假若我們有一假想資料(hypothetical data)，內容包括年齡、出生年月日、診斷日期、死亡日期、發現方法、死亡原因、治療方法。

若以 ASCII 固定格式來表示為：

5411/09/3511/22/8902/03/9931741

若以自由格式且以逗號隔開則表示為：

54,11/09/35,11/22/89,02/03/99,3,174,1

年齡 出生日期 診斷日期 死亡日期 發現方法 死亡原因 治療方法

三、常使用之統計軟體

(一) SAS

(二) SPSS

(三) S-plus

(四) BMDP

(五) Egret、STATA、MINTAB、GLIM

以下是簡單之比較

軟體種類	資料處理能力	容易使用	統計完整性
SAS	++++	+	++++
SPSS	+	+++	++
S-plus	+	++	++
BMDP	+	+	+++
Egret	+	+++	++

四、SAS 軟體使用簡介

SAS 處理資料基本上分成三個階段：

(一) 資料步驟(Data Step)

(二) 控制流程及敘述(Control language & Statement)

(三) 統計步驟(Proc Step)

分別介紹如下：

第一部份

資料步驟 (Data Step)

1. 內建資料
2. 外部讀檔
3. 讀取複雜資料
4. SAS 永久檔產生方法及開啟
5. SAS 暫時檔概念
6. SAS 載入及載出 Excel 及 Dbase 檔案
7. SAS 分析後產出檔

(一) Data Step(資料)

1. 內建資料

(1) 自由格式(範例一)

→ PROGRAM EDITOR 視窗

```
Data xx;  
    informat dob dop ddeath mmddyy8.;  
    input age dob dop ddeath mode cause Tx;  
    cards;  
    54 11/09/35 11/22/89 02/03/99 2 174 1  
    ;  
proc print;  
run;
```

→ LOG 視窗

```
1 Data xx;  
2     informat dob dop ddeath mmddyy8.;  
3     input age dob dop ddeath mode cause Tx;  
4     cards;  
NOTE: The data set WORK.XX has 1 observations and 7 variables.  
NOTE: The DATA statement used 0.22 seconds.  
6     ;  
7 proc print;  
8 run;  
NOTE: The PROCEDURE PRINT used 0.11 seconds.
```

→ OUTPUT 視窗

OBS	DOB	DOP	DDEATH	AGE	MODE	CAUSE	TX
1	-8819	10918	14278	54	2	174	1

自由格式(範例二)

→ PROGRAM EDITOR 視窗

```
data x;  
    input age dob: mmddyy8. dop: mmddyy8. ddeath : mmddyy8.
```

```

mode cause tx;
cards;
54 11/09/35 11/22/89 02/03/99 2 174 1
;
run;
proc print;
run;

```

→ LOG 視窗

```

9 data x;
10 input age dob: mmddyy8. dop: mmddyy8. ddeath: mmddyy8.
11 mode cause tx;
12 cards;
NOTE: The data set WORK.X has 1 observations and 7 variables.
NOTE: The DATA statement used 1.26 seconds.
14 ;
15 run;
16 proc print;
17 run;
NOTE: The PROCEDURE PRINT used 0.05 seconds.

```

→ OUTPUT 視窗

OBS	AGE	DOB	DOP	DDEATH	MODE	CAUSE	TX
1	54	-8819	10918	14278	2	174	1

(2) 固定格式

→ PROGRAM EDITOR 視窗

```

Data xx;
input age 1-2 dob $ 3-10 dop $11-18 ddeath $19-26
mode 27 cause 28-30 tx 31;
cards;
5411/09/3511/22/8902/03/9921741
;
proc print;
run;

```

→ LOG 視窗

```
18 Data xx;
19     input age 1-2 dob $ 3-10 dop $11-18 ddeath $19-26
20 mode 27 cause 28-30 tx 31;
21 cards;
NOTE: The data set WORK.XX has 1 observations and 7 variables.
NOTE: The DATA statement used 1.31 seconds.
23 ;
24 proc print;
25 run;
NOTE: The PROCEDURE PRINT used 0.05 seconds.
```

→ OUTPUT 視窗

OBS	AGE	DOB	DOP	DDEATH	MODE	CAUSE	TX
1	54	11/09/35	11/22/89	02/03/99	2	174	1

2. 讀取及儲存外部 ASCII 檔案

→ PROGRAM EDITOR 視窗

(1) 讀取 ASCII 檔案

```
Data xx;
  infile '使用者指定名稱';
  input age dob dop ddeath mode icd Tx;
run;
```

** 在 SAS 之日誌(log)上應可以看到讀取外部檔案其最大長度及最小長度，同樣地在日誌上應可以看到會產生一個 work.xx。

(2) 載出 ASCII 檔案

```
Data a;
  input sex bod $dhiv $ daids $ cd4 rf;
  cards;
1 11/09/65 11/22/80 02/03/85 300 2
```



```
;
run;
```

```
Data xx;
  set a;
  file '使用者指定名稱';
  put sex dob $ dhiv $ daids $ cd4 rf;
run;
```

3. SAS 讀取複雜資料

(1) 讀取資料每一筆超過 2 行

→ PROGRAM EDITOR 視窗

```
Data xx;
  input #1 age dob $ dop $ ddeath $
        #2 mode icd tx;
  cards;
    54 11/09/35 11/22/89 02/03/99
    2 174 2
  ;
  proc print;
run;
```

→ LOG 視窗

```
1      Data xx;
2          input #1 age dob $ dop $ ddeath $
3              #2 mode icd tx;
4          cards;
NOTE: The data set WORK.XX has 1 observations and 7 variables.
NOTE: The DATA statement used 1.15 seconds.
7      ;
8          proc print;
9          run;
NOTE: The PROCEDURE PRINT used 0.22 seconds.
```

→ OUTPUT 視窗

OBS	AGE	DOB	DOP	DDEATH	MODE	ICD	TX
1	54	11/09/35	11/22/89	02/03/99	2	174	2

(2) 可以用指定欄位(@)方式讀取資料

→ PROGRAM EDITOR 視窗

```
Data xx;
  input @1 age 2.
        @3 dob mmddyy8.
        @11 dop mmddyy8.
        @19 ddeath mmddyy8.
        @27 mode 1.
        @28 cause 2.
        @30 tx 1.;
cards;
5411/09/3511/22/8902/03/9921742
;
proc print;
run;
```

→ LOG 視窗

```
1 Data xx;
2     input @1 age 2.
3         @3 dob mmddyy8.
4         @11 dop mmddyy8.
5         @19 ddeath mmddyy8.
6         @27 mode 1.
7         @28 cause 2.
8         @30 tx 1.;
9     cards;
NOTE: The data set WORK.XX has 1 observations and 7 variables.
NOTE: The DATA statement used 0.55 seconds.
11 ;
12 proc print;
```

13 run;

NOTE: The PROCEDURE PRINT used 0.48 seconds.

→ OUTPUT 視窗

OBS	AGE	DOB	DOP	DDEATH	MODE	CAUSE	TX
1	54	-8819	10918	14278	2	17	4

(3) 可以在同一行讀取多筆資料

→ PROGRAM EDITOR 視窗

```
Data xx;
  input age dob $ icd @@;
  cards;
    1 11/09/35 174 2 02/03/32 250
    2 12/02/31 174 1 01/03/30 174
  ;
proc print;
run;
```

@@代表告訴 SAS 讀取同一行資料直到沒有資料再跳到下一行。

→ LOG 視窗

```
9 Data xx;
10 input age dob $ icd @@;
11 cards;
NOTE: SAS went to a new line when INPUT statement reached past the end
of a line.
NOTE: The data set WORK.XX has 4 observations and 3 variables.
NOTE: The DATA statement used 0.66 seconds.
14 ;
15 proc print;
16 run;
NOTE: The PROCEDURE PRINT used 0.0 seconds.
```

→ OUTPUT 視窗

OBS	AGE	DOB	ICD
1	1	11/09/35	174
2	2	02/03/32	250
3	2	12/02/31	174
4	1	01/03/30	174

(4) 讀取非結構性(Unstructured)資料

假設有一隨機試驗資料其實驗組及控制組在服用及未服用藥物後其體內某種生化值濃度如下，

實驗組	對照組
20	40
25	42
23	35
27	30

→ PROGRAM EDITOR 視窗

```

Data xx;
  input group $ x @@;
cards;
  T 20 T 25 T 23 T 27 C 30
  C 40 C 42 C 35
;
proc print;
run;

```

→ OUTPUT 視窗

OBS	GROUP	X
1	T	20
2	T	25
3	T	23
4	T	27

5	C	30
6	C	40
7	C	42
8	C	35

**因只有 5 筆資料故重覆寫不致於太煩，如果現有大量之資料，則利用上述方法會相當煩，

可以改用下列 SAS 指令，

→ PROGRAM EDITOR 視窗

```

Data xx;
  Group='T';
  Do I=1 to 4;
    input x @;
    Output;
  End;
  Group='C';
  Do I=1 to 4;
    input x @;
    Output;
  End;
  Drop I;
  cards;
    20 25 23 27 30 40 42 35
  ;
proc print;
run;

```

→ OUTPUT 視窗

同上。

4. SAS 永久檔產生方法及開啟

當處理大量資料時，若每次 SAS 必須讀取外部檔案則相當耗時，SAS 可以利用儲存永久檔之方式來節省時間。以下是有關 SAS 永久檔之觀念及儲存方法：

(1) SAS 資料集(Dataset)之觀念

SAS 儲存資料集可以分為暫時儲存及永久儲存。若是以永久儲存方式則須使用 Library 之觀念，也就是 SAS 必須先宣告這個資料集(Dataset)儲存之位置，其指令如下：

→ PROGRAM EDITOR 視窗


```
libname hh '使用者指定路徑';
```

```
Data hh.xx;  
    informat dob dop ddeath mmddyy8.;  
    input age dob dop ddeath mode icd tx;  
    cards;  
    54 11/09/65 11/22/80 02/03/85 2 174 2  
;  
run;
```

→ LOG 視窗

```
1  libname hh '使用者指定路徑';  
NOTE: Libref HH was successfully assigned as follows:  
      Engine:          V612  
      Physical Name: 使用者指定路徑  
2  Data hh.xx;  
3      informat dob dop ddeath mmddyy8.;  
4      input age dob dop ddeath mode icd tx;  
5      cards;  
  
NOTE: The data set HH.XX has 1 observations and 7 variables.  
NOTE: The DATA statement used 0.48 seconds.  
7  ;  
8  run;
```

**hh 是參考名稱，使用者可以自己定名稱，而這個參考名稱可以每次使用不同，其和永久檔名稱之關係可以用下列方式來表示：



上圖表示 SAS 利用參考名稱將所欲存入之永久檔指向使用者路徑，如此雖然離開 SAS 後，這個永久檔也會以永久檔儲存 xx.sd2(xx 是永久檔名)，在使用者指定之路徑，如果使用檔案總管可以看到 xx.sd2 之檔案。

(2) 開啟永久檔

當使用者欲使用所儲存之永久檔則可利用下列指令打開這個永久檔：

```
libname hh '使用者指定路徑';
data xx;
  set hh.chen;
run;
```

其觀念如下：使用者可以使用 libname 之指令透過參考名稱到'使用者指定路徑'(這個參考名稱可以和上次不同)尋找 set 指令後面之永久檔。

5. SAS 暫時檔

SAS 可以將資料集(Dataset)以暫時檔方式存取，其儲存方式如下：

```
Data a;
  informat bod dhiv daids mmdyy8.;
  input sex bod dhiv daids cd4 rf;
  cards;
```

```

1 11/09/65 11/22/80 02/03/85 300 2
;
run;


```



如此 SAS 將以 work.a 方式儲存於 C:\SAS\SASWORK 形成暫存檔，而這個暫檔在此次離開 SAS 之後會自動消失。

6. SAS 載入及載出 Excel 及 Dbase 等相關檔案

SAS 6.12 版在讀取以 dBASE, Lotus 及 Excel 建檔資料時可以使用 Pop-up Menu 中之 Import 之功能，並且在載出檔案時也可使用 Pop-up Menu 中之 Export 方式。

8. 載入 excel 檔案





7. SAS 分析後產出檔 (Post-analyzed Data)

利用 SAS 做資料處理最大的好處是可以將分析結果變成另一個資料檔，這種資料產出方式稱為 Post-analyzed Data。

例一：以乳癌為例假設我們要產生年齡 40-49、50-59、60-69、70+ 在實驗組與對照組乳癌個案淋巴侵襲程度(沒有侵襲、侵襲及轉移)之檔案，我們可以使用下列指令來完成：

```
libname hh 'c:\';  
proc freq data=hh.tx1;  
    table gp*age*nodes/out=d sparse noprint;  
run;  
proc print data=d;  
run;
```

第二部份

控制流程及敘述

1. 新變項產生
2. 重新定義變項
3. First.variable 與 Last.variable 指令應用
4. 如何使用 SAS Array
5. SAS 資料聯結
6. SAS 函數

SAS 處理資料最強之處在於條件控制流程，然而使用這些指令及敘述會因使用者之主題而不同，並沒有統一格式，以下僅介紹幾種常用之指令。

1. 新變項之產生

以上述乳癌為例，若我們欲產生得診斷之年齡可以使用得診斷之日期減去生日(dob)，其程式如下，

```
RAGE=DOP-DOB;
```

RAGE 是新產生之變項。

* SAS 在執行一個敘述時，其執行迴圈是視資料次數而定，如果資料是 200 筆，則 SAS 在執行此道敘述時其內建程式自動會做 200 次。

2. 重新定義變項

在一般資料分析中，通常會須要重新定義變項，例如：將年齡(Age)分成類別變項(1-10, 11-19, ...)，一般而言，處理這樣問題是屬於 SAS 第二步問題，SAS 處理如此問題有下列幾種方法

(1) 數值變項重新分類--一個變項分類

IF-THEN/ELSE 敘述

例：SIZE 重新分類

```
If size>20mm then sizegp=1;  
else                sizegp=0;
```

If 後面之 size>20mm 運算式是用來判斷條件是否滿足，若滿足則執行 then 後面之 Statement，若沒有滿足則執行 else 之 statement(如果 If 後面沒有 else 指令，則執行下一個敘述)。

(2) 牽涉二個以上變項分類

DO-END

```
If (size>20) then do;
    level=1;
    stage=3;
end;
else if (size>10 & size<20) then do;
    level=2;
    stage=2;
end;
else do;
    level=3;
    stage=1;
end;
```

例：下列年齡資料分類成<10，10-19，20-29，30-39，40-49 五組

```
DATA GROUP 1;
    INPUT AGE;
        IF AGE>=0 & AGE<10 THEN AGEGROUP=0;
        ELSE IF AGE>=10 & AGE<20 THEN AGEGROUP=10;
        ELSE IF AGE>=20 & AGE<30 THEN AGEGROUP=20;
        ELSE IF AGE>=30 & AGE<40 THEN AGEGROUP=30;
        ELSE IF AGE>=40 & AGE<50 THEN AGEGROUP=40;
    CARDS;
data lines
;
PROC PRINT;
    TITLE 'DATA SET GROUP1';
RUN;
```

結果如下，

OBS	AGE	AGEGROUP
1	.	.
2	1	0
3	3	0
4	7	0

5	9	0
6	12	10
7	17	10
8	21	20
9	27	20
10	30	30
11	31	30
12	36	30
13	41	40
14	43	40
15	49	40
16	51	.

除了上述方法也可以使用 descending 方法來分類，不過使用這種方法必須注意的是不要再使用 else 因為可能會有超過一個以上 IF 條件會滿足，因此容易出錯，使用上要非常小心。

```
DATA GROUP4;
  INPUT AGE;
  AGEGROUP=40;
  IF AGE<40 THEN AGEGROUP=30;
  IF AGE<30 THEN AGEGROUP=20;
  IF AGE<20 THEN AGEGROUP=10;
  IF AGE<10 THEN AGEGROUP=0;
CARD;
data lines;
PROC PRINT;
  TITLE 'DATA SET AGEGROUP4';
RUN;
```

結果如下，

OBS	AGE	AGEGROUP
1	.	0
2	1	0
3	3	0
4	7	0
5	9	0
6	12	10
7	17	10
8	21	20
9	27	20
10	30	30

11	31	30
12	36	30
13	41	40
14	43	40
15	49	40
16	51	40

(3) 使用 Logical 方法

```
DATA GROUP5;
  INPUT AGE;
  AGEGROUP=10*(10<=AGE<20)+20*(20<=AGE<30)+
    30*(30<=AGE<40)+40*(40<=AGE<50);
  CARDS;
data lines
;
PROC PRINT;
  TITLE 'DATA SET GROUP5';
RUN;
```

結果如下，

OBS	AGE	AGEGROUP
1	.	0
2	1	0
3	3	0
4	7	0
5	9	0
6	12	10
7	17	10
8	21	20
9	27	20
10	30	30
11	31	30
12	36	30
13	41	40
14	43	40
15	49	40
16	51	0

使用 Logical 方法主要是評估括弧內敘述是否為真；若為真則為 1，若為假則為 0，例如：

如果 Age 為 15 則敘述(10<=Age<20)=1

特殊方法：下列敘述先將 Age 除以 10 取整數後再乘以 10.

```
Data group7;  
  Input age;  
  Agegroup=int(age/10)*10;  
  Cards;  
Datalines;  
  ;  
proc print;  
run;
```

(4) 字元變項重新分類

(A)基本上字元變項重新分類方法和數值變項相同，不過因為為類別變項，所以會有長度問題，例如下列二個敘述基本上是相同的

(1) If age='4' then agegroup=40;

(2) If age='4 ' then agegroup=40;

因為 SAS 將較短值加上空白至長度和較長值相同，如 Age 是長度

為 2 之 character，SAS 自動將'4'延伸為'4 '，而比較 Age 並沒有這樣值所以上述 IF 條件並沒有任何觀察值滿足。為了克服上述問題 SAS 利用加入 semicolon(:)來克服此問題

If age =:'4' then agegroup=40;

加入：SAS 會比較 Age 第一個字元，而將後面長度數值裁掉，不再加入空白。

```
DATA GROUP9;  
  INPUT AGE $CHAR2.;  
  IF AGE=: ' ' THEN AGEGROUP=10;  
  ELSE IF AGE=: '1' THEN AGEGROUP=10;  
  ELSE IF AGE=: '2' THEN AGEGROUP=20;  
  ELSE IF AGE=: '3' THEN AGEGROUP=30;  
  ELSE IF AGE=: '4' THEN AGEGROUP=40;  
  CARDS;
```

Data lines

;

PROC PRINT;

TITLE 'DATA SET GROUP9;

RUN;

OBS	AGE	AGEGROUP
1	.	0
2	2	0
3	13	10

4	24	20
5	36	30
6	47	40

(B) 使用 Substr 截取字元變項：另外一種方法截取字元變項方法是使用 Substr 指令，其使用方法為

Substr (變項名稱，第幾個字元，長度)

以上述 Age 為例，截取第一個字並加上 0 在後面為

```
DATA GROUP 10;
  INPUT AGE $CHAR2.;
  AGEGROUP=SUBSTR(AGE,1,1)||'0';
  CARDS;
.
2
13
24
36
47
51
;
PROC PRINT;
  TITLE 'DATA SET GROUP10;
RUN;
```

OBS	AGE	AGEGROUP
1	.	0
2	2	0
3	13	10
4	24	20
5	36	30
6	47	40
7	51	50

(5) 列印重新分類之變項：有時為了在列印時表不重新分類變項其意義，可以使用 proc format 先定義變項意義，然後在跑 proc 再使用 format 來顯示其意義，例如下列 age 之重新分類。

```

PROC FORMAT;
  VALUE AGEFMT 0-9=' 0'
              10-19='10'
              20-29='20'
              30-39='30'
              40-49='40';
PROC FREQ;
  TABLES AGE;
  FORMAT AGE AGEFMT.;
  TITLE 'FREQUENCY TABLE2';
RUN;

```

(6) 數值變項→字元變項及字元變項→數值變項

(A) 數值→字元：使用 put 函數，put(argument,format)

將 argument(通常是變項名稱)轉成後面 format(可以是 SAS format 也可以是已經定義過 format)，以上述年齡為例

```
agegroup=put(age,agefmt)
```

SAS 利用上述 agefmt 之 format 將 age 轉成 agegroup 字元變項

(B) 字元→數值：相同地，SAS 利用 input 指令

input(argument,informat)將字元變成數值

```
agegrp=input(agegroup,2.);
```

SAS 將 agegroup 字元變項透過 input 函數讀成數值變項長為 2 之 Agegrp.

3. First.variable 與 Last.variable 指令應用

SAS 程式中經常會使用上述 2 個指令來處理重覆資料，有關 first.variable 及 last.variable 之指令之觀念如下，

(1) 這兩個變項是 SAS 內部自動產生之變項

(2) 使用這兩個變項之前必須先利用 sort 之指令來 sort 這個變項

(3) 使用這兩個變項是在 set 指令之後使用 by 指令

(4) first.variable 及 last.variable 僅有 0 及 1 兩種結果，也就是依這個變項 sort 之後其第一筆

觀察值 first.variable=1，其他為 0，最後一筆觀察值 last.variable=1，其他為 0。

例如有一個人其膽固醇在不同時間會有不同之測量值如下，

ID	Time (month)	Cholesterol	First.id	Last.id
1	5	123	1	0
1	10	145	0	0
1	12	185	0	1
2	4	196	1	0
2	6	205	0	0
2	8	221	0	1

若根據 sort 將 ID 排序後其 First.id 及 Last.id 之情況如上。

(1) 列出每個病人第一點時間其膽固醇狀態

```
data x;
  input id cho;
  cards;
  1 123
  1 145
  1 185
  2 196
  2 205
  2 221
  ;
run;

proc sort data=x;
  by id;
data y;
  set x;
  by id;
  if first.id;
proc print;
run;
```

(2) 列出每個病人其膽固醇最差之狀態

```
data worse;
  set x;
  by id;
  if first.id then worse=.;
  retain worse;
  worse=max(cho,worse);
  drop cho;
  if last.id then output;
run;
proc print;
run;
```

(3) 若不管病人為誰，可否將相同時間之病人數列出

```
data a;
input id cho time @@;
cards;
1 123 6 1 145 6
1 185 6 1 150 3
1 168 3 1 278 12
2 196 4 2 205 4
2 221 8 2 196 8
2 208 6 2 297 6
2 268 6
;
proc sort data=a;
  by time;
data agg;
  set a;
  by time;
  if first.time then num=0;
  num+1;
  if last.time;
run;
proc print;
run;
```

4. 如何使用 SAS array:

學習使用 SAS array 對於資料處理上相當重要，學會使用 array 可以讓使用 SAS 者節省很多時間，以下介紹常用之實例。

(1) 利用 Array 來避免重覆宣告相同遺漏值之指令

```
Data xx;
  input a b c d e;
    if a=999 then a=.;
    if b=999 then b=.;
    if c=999 then c=.;
    if d=999 then d=.;
    if e=999 then e=.;
  cards;
    24 25 26 999 999
    999 21 24 26 27
    20 999 999 21 23
    25 26 999 27 999
    999 28 27 999 30
  ;
run;
```

上述是利用傳統方法來定義 a, b, c, d, e 之遺漏值，我們可以使用 Array 來避免煩雜手續。

```
Data xx;
  input a b c d e;
    array x{5} a b c d e;
    do i=1 to 5;
      if x{i}=999 then x{i}=.;
    end;
    drop i;
  cards;
    24 25 26 999 999
    999 21 24 26 27
    20 999 999 21 23
    25 26 999 27 999
    999 28 27 999 30
  ;
run;
```

※有時在 Array 使用上可以使用* (配合 DIM 函數) , 不須算到底有幾個變項如下例

```
DATA CHANGE;
  INPUT A B C D E F;
  ARRAY EVERY{*}_NUMERIC_;
  DO J=1 TO DIM(EVERY);
    IF EVERY{J}=9 THEN EVERY{J}=.;
  END;
  DROP J;
  CARDS;
0 0 0 0 0 0
1 1 1 1 1 1
2 9 2 9 2 9
3 3 3 3 3 3
1 9 1 9 1 9
;
PROC PRINT;
  TITLE 'DATA SET CHANGE';
RUN;
```

(2)暫時 Array 之使用有時可以使用暫時 array, 而不須製造變項, 以下舉一例有關多重生化之應用

```
Data abnormal;

  Array abnorm{5} (126 220 45 45 40);
  Array test{5};

  Input ID $ test1-test5;
  ab_num=0;
  do i=1 to 5;
    if test{i}>=abnorm{i} then
      ab_num+1;
  end;
  drop i;

cards;
```

```

001 127 219 68 69 60
002 113 280 41 42 36
;
run;
proc print; run;

```

(3) 利用 Array 將每個人重覆測量之值轉換成一個測量值一筆資料

(Variable → Observation)

(A) 例如有一筆資料是每個人測量三次之值，表示如下，

SUBJ	X ₁	X ₂	X ₃
1	10	11	13
2	5	6	8

我們欲將其表示如下，

SUBJ	TIME	X
1	1	10
1	2	11
1	3	13
2	1	5
2	2	6
2	3	8

其 SAS 指令如下，

```

Data ex6;
  input subj x1 x2 x3;
  cards;
  1 10 11 13
  2 5 6 8
  ;
run;

```

```

Data ex7;

```



```

set ex6;
time=1;
x=x1;
output;
time=2;
x=x2;
output;
time=3;
x=x3;
output;
drop x1-x3;
run;

```

```
proc print;
```

```
run;
```

或以下列表示，

```

Data ex7;
  set ex6;
  array xx{3} x1-x3;
  do time=1 to 3;
    x=xx{time};
    output;
  end;
  drop x1-x3;
run;
proc print;
run;

```

(B) 假如您有一個 data，每筆觀察值有 3 個 diagnosed code (DX1,DX2,DX3)

ID	DX1	DX2	DX3
01	3	4	
02	1	2	3
03	4	5	
04	7		

如何將其變成

ID	DX
01	3
01	4
02	1
02	2
02	3
03	4
03	5
04	7

```
Data new_dx;  
  Set diagnose;  
  array DXARRAY{3} DX1-DX3  
  Do i =1 to 3  
    DX=DXARRAY{i}  
    If DX ne. then output;  
  End;  
  Keep id DX;  
RUN;
```

(C) 假如您有筆病人測量三次高血壓資料(收縮壓)

ID	S1	S2	S3
01	126	118	132
02	110	118	116
03	98	100	102

如何將其變成觀察值呢？

```
data one;  
input id s1 s2 s3;  
cards;  
01 126 118 132  
02 110 118 116  
03 98 100 102  
;  
run;  
data multiple;
```

```

set one;
array SBP{3} s1-s3 ;
do time=1 to 3;
SBPS=SBP{time};
output;
end;
run;

```

甲、利用 Multi-dimension array 將變項變成觀察值

如果您有筆一觀察值測量 6 次體重值，前三次是在某減肥計畫之前而後三次是減肥計畫之後，其 data 如下

ID	WT1	WT2	WT3	WT4	WT5	WT6
01	155	158	162	149	148	147
02	110	112	114	107	108	109

(Create data WT_1)

如何轉變成觀察值？

因為有減肥前後體重，如此將 6 次體重變成 6 筆觀察值二組 array,其 program 如下

```

data wt_1;
input id wt1-wt6;
cards;
01 155 158 162 149 148 147
02 110 112 114 107 108 109
;
run;

```

```

Data WT_6;
Set WT_1;
Array WTID{2,3}WT1-WT6;
Retain WT1-WT6;
Do I=1 to 2
  Do time=1 to 3;
    Weight=WTID{I,time};
  Output; End;
Drop WT1-WT6;
End;
proc print;
run;

```

```
proc sort data=wt_many;
```

```

    by id cond time;
run;

data wt_one;
    array wt[2,3] wt1-wt6;
    retain wt1-wt6;
    set wt_6;
    by id;
    if first.id then
        do i=1 to 2;
            do j=1 to 3;
                wt[i,j]=.;
            end;
        end;
    wt[cond,time]=weight;
    if last,id then output;
    keep id wt1-wt6;
run;

proc print data=wt_one;
    title 'wt_one again';
run;

```

(4) 利用 Array 將同一個人不同測量值之觀察值變成變項(Observation→Variable)

(A) 假如我們有一筆同一個人 5 個時間點之測量值資料，

SUBJ	TIME	X	Y	Z
1	1	5	6	7
1	2	6	7	8
1	3	6	6	6
1	4	3	4	5
1	5	7	8	9
2	1	4	5	6

2	2	4	5	7
2	3	5	7	9
2	4	5	8	8
2	5	8	8	9

我們欲將其變成

SUBJ	X1	X2	X3	X4	X5	Y1	Y2	Y3	Y4	Y5	Z1	Z2	Z3	Z4	Z5
1	5	6	6	3	7	6	7	6	4	8	7	8	6	5	9
2	4	4	5	5	8	5	5	7	8	8	6	7	9	8	9

其 SAS 指令如下：

```

Data multiple;
  input subj time x y z;
  cards;
  1 1 5 6 7
  1 2 6 7 8
  1 3 6 6 6
  1 4 3 4 5
  1 5 7 8 9
  2 1 4 5 6
  2 2 4 5 7
  2 3 5 7 9
  2 4 5 8 8
  2 5 8 8 9
  ;
run;
proc sort data=multiple;
  by subj time;
run;
Data oneper;
  set multiple;
  by subj time;
  array xx{*} x1-x5;
  array yy{*} y1-y5;
  array zz{*} z1-z5;
  /* retain x1-x5 y1-y5 z1 z5; */
  if first.subj then

```

```

do i=1 to 5;
    xx{i}=.; yy{i}=.;zz{i}=.;
end;
xx{time}=x;
yy{time}=y;
zz{time}=z;
if last.subj then output;
keep subj x1-x5 y1-y5 z1-z5;
run;
proc print;
run;

```

這個 SAS 指令其最重要的觀念是：

首先必須了解這和上述是相反的(將 Observation 變成 Variable)，Retain 指令是用來防止 SAS 在讀取一個新觀察值會將變項宣告為 missing，直到 SAS 遇到一個新值或執行下一個敘述，因此若不使用 retain，當執行 XX{TIME}, YY{TIME}, ZZ{TIME}時，因必須等到一個 subj 之最後一筆資料(Last.subj=1 滿足時)SAS 才會將一筆資料寫出去，如此會造成 X1-X4 會變成 missing 值，僅有 X5 會有數值(嘗試將 retain 指令去掉以檢視結果變成如何)。

(B) 例如每人測量三次血壓值得到資料如下：

ID	test	
01	1	126
01	2	118
01	3	127
02	1	98
02	2	104
02	3	103
03	1	112
03	2	108
03	3	110

如何將其變成變項呢？

通常必須配合 first variable 及 last variable 指令

如同前述使用 first variable 及 last variable 必須先針對資料做 sort 的動作，其 program 如下：

```
proc sort data=SBP;
  by id;
data test (keep=id test1-test3);
do j=1 to 3;
  set sbp;
  by id;
  convert{jj}=sbp;
  if last.id then output;
end;
proc print;
run;
```

上述 program 中 SAS 利用 Array 指令指定如因果 ID=1 time=1 sbp=126，如此 convert{jj}=convert{1}，convert{1}代表變項 test1，而設定此值為 126，因為 last.id 是 false output 指令不會 work。SAS 繼續讀取下一筆觀察值 last.id 條件滿足為止，SAS 完成第一筆觀察值寫出。

上述利用 array 將觀察變成變項是當每筆觀察值皆有 3 次測量值，如果有些觀察值其並沒有 3 次測量值則可能必須利用 first.id 來 check 條件，以上例而，如果 ID=2 第二筆觀察值 missing，則 SAS program 因為利用 retain 指令保留 test2 為上筆觀察值，因此必須利用 first.id 來防止其發生，其 program 如下。

```
Data sbp;
array convert{3} test1-test3;
retain test1-test3;
set sbp;
by id;
if first.id then do j=1 to 3;
  convert{jj}=.;
end;
convert{jj}=sbp;
```

```
if last.id then output;
run;
```

5. SAS 資料聯結(包括 merge 及 concatenating)

(1) Merge

今有 2 個 dataset，一個是主檔，另一個其他檔，欲將其資料合併成一個檔案，使用下列程式

```
Data a;
  input ss name $;
  cards;
    123456789 Cody
    987654321 Smith
    111223333 Gegory
    222334444 Tony
    777665555 Chambliss
  ;
run;
```

```
Data b;
  input ss cd4;
  cards;
    123456789 300
    987654321 100
    222334444 200
  ;
run;
```

其合併程式前必須對這個檔案進行排序(sort)

```
Proc sort data=a;
  by ss;
run;
Proc sort data=b;
  by ss;
run;
```



```

data ab;
  merge a b;
  by ss;
run;

```

(2) Concatenating

如果今有另一新的資料再進來，例如：

```

Data a;
  input ss name $;
  cards;
    666334444 Lias
    222556666 Teresa
  ;
Data ac;
  set a c;
run;

```

在合併資料時，我們經常希望所合併資料僅含有我們所想要之變項，此時可以在 Merge 指令後面使用 IN 之選擇項，如下述 IN 之 option 中使用這個 logical expression，選擇 score 沒有 missing 三個觀察值。

```

data ac;
merge a b (in=x);
by ss;
if x;
run;

```

(1) 在處理資料，有時會有一個主檔(Master File)，而所欲合併資料是修改檔(Updated File)，此時可以使用 Update 指令如下例：

Patient ID	SBP	
01	126	
02	118	主檔 (x)
03	108	

04	140	
最近測量而血壓為		
01	102	
03	100	Updated (y)
04	122	

可以使用 Update 指令

```
data xy;
update x y;
by id;
run;
```

6. 將 SAS 的 output 資料建立成另一資料庫

SAS 處理資料中最大優點是可將所得到之統計結果，儲存成另一個資料集，以便利於下一步之計算使用，

例：假如我們有一筆資料如下，

Heart Rate	SBP	DBP
80	160	100
70	150	90
60	140	80

我們欲將 Heart Rate, SBP 及 DBP 各除以其平均值再乘以 100%，則如何計算，

可以利用下列 SAS 指令

```
Data test;
  input hr sbp dbp;
  cards;
  80 160 100
  70 150 90
  60 140 80
  ;
run;
```

```

proc means ;
  var hr sbp dbp ;
  output out=mout mean=mhr msbp mdbp;
run;
data new;
  set test;

  if _N_=1 then set mout;

  hper=100*hr/mhr;
  sbpper=100*sbp/msbp;
  dbpper=100*dbp/mdbp;

run;
proc print;
run;

```

利用 Proc means 將 HR, SBP 及 DBP 之平均值 output 至一個檔案，再叫出這個檔案製造新變項

```

HPER=100*HR/MHR
SBPPER=100*SBP/MSBP
DBPPER=100*DBP/MDBP

```

上述指令同時 set 兩個檔案 test 及 mouth，因為 test 有 3 筆資料而 mouth 僅有一筆資料，因此可以使用 SAS 內定值 `_N_=1` 來告訴 SAS 在 test 檔案加入僅有一筆觀察值 mouth data 中 HR, SBP 及 DBP 之平均值。

7. 常用 SAS 函數

(1) 數學函數：常用 SAS 數學函數包括

log：以自然指數為底

log10：以 10 為底

INT：小數點部份去掉

SQRT : $\sqrt{\quad}$

Round : (argument,unit)

例：Round(X,1)⇒取 X 至最近整數

Round(X, .1)⇒取 X 至最近 1/10

Round(X,100)⇒取 X 至最近 100

Round(X,20)⇒取 X 至最近 20

mean (of 變項 1-變項 N)

例：取 X1-X5 平均值，其最近變項為

Mean_X=Mean(of X1-X5)

在 X1-X5 皆沒有 missing 下，上述指令相同，

$$\text{Mean_X} = \frac{X_1 + X_2 + \dots + X_4 + X_5}{5}$$

但若 X_5 是 missing，則使用第二種方法，Mean_X 為 missing，而第一種方法，SAS 只計算 $X_1 - X_4$ 之平均值，並不會宣告為 missing value。

(2) 長期追蹤資料中日期變項處理：在長期追蹤資料中因為會得出不同時間測量，因此如何處理日期變項變成相當重要，SAS 在處理日期變項提供多種方式包括

102150 MMDDYY

10/21/50 MM/DD/YY

211050 DDMMYY

例：下列是一組病人出入院相關資料

ID	DOB	Admission Date	Discharge Date	DX	Fee
001	102150	091090	091390	8	3000

您可以用下列方式讀入

input @1 id 3.@5 dob mmddyy6. @12 admit mmddyy6.

@18 dischrg mmddyy6. @25 dx 1. @26 fee 5.;

COLUMN

ID

1-3

DOB	5-10
ADMIT	12-17
DISCHARG	18-23
DX	25
FEE	26-30

但這樣方式並非以日期型式讀入，下列是以日期方式讀入，

```
input @1      id      3.
      @5      dob      mmddyy6.
      @12     admit    mmddyy6.
      @18     dischrg   mmddyy6.
      @25     dx        1.
      @26     fee       5.;
```

若以上述日期來宣告，SAS 在結果會以內定日期數值(Internal data value)來顯示，也就是 SAS 會將您輸入之日期與內定日期 January 1, 1960 相減得到一個內定數值，以上述而言，102150 在結果之螢幕上所顯示為-3359。

今欲計算住院年齡及住院日期(Length of stay)，其 program 如下。

長期追蹤資料實例：

如何計算住院年齡(Age)及住院日(LOS)

$$\text{Age} = (\text{Admit} - \text{dob}) / 365.25$$

$$\text{Age} = \text{Floor}((\text{Admit} - \text{dob}) / 365.25)$$

$$\text{LOS} = \text{DISCHRG} - \text{ADMIT}$$

(3) 隨機亂數函數(Ranuni)：SAS 利用 Ranuni 函數產生隨機亂數 0~1 之間，其使用方法有 2 種：

(A) 使用 Ranuni(0)：產生隨機亂數是根據 Time lock，所以每次產生數值都不相同。

(B) 使用 Seed：使用一個 internal number，稱 seed 產生隨機亂數。

例：

```

data shuffle;
    input name : $20.;
    X=ranuni(0);
datalines;
cody
smith
martin
lavery
thayer
;
proc sort data=shuffle;
    by x;
run;

proc print data=shuffle;
    title 'Names in Random Order';
    var name;
run;

```

(4) 隨機亂數產生(Random Number Generation)

(A) SAS 可以利用 Ranuni 之均等函數產生 0~1 之隨機變數

例如我們欲產生 X1 及 X2 之兩個隨機變數，其分佈是屬於(0~1)之均等分佈

```

data a ;
    retain seed1 seed2 345678921;
    do i=1 to 100;
        x1=ranuni(seed1);
        x2=ranuni(seed2);
        output;
    end;
proc print;
run;

```

(B) 我們也可以使用 CALL 之函數來產生(0~1)之隨機變數

```

data b ;
  retain seed1 seed2 345678921;
  do i=1 to 100;
    call ranuni(seed1,x4);
    call ranuni(seed2,x5);
    output;
  end;
proc print;
run;

```

(C) 利用 Ranuni 之隨機亂數器做簡單隨機抽樣

例如：我們使用上述隨機亂數所產生之 dataset b，我們欲抽取約 1/4 sample 則可以使用下列指令來達成

```

data random;
  set b;
  if ranuni(784561) <=0.25;
run;
proc print;
run;

```

(D) 抽樣分佈之產生

(a) 常態分佈

假如我們有一個常態分佈 $N(0,25)$ [即平均值是 0，變異數是 25] 之分佈，我們可以使用 Rannor 之指令來產生樣本，例如我們想要產生一個樣本數為 100 的樣本是來自這個母群體，其指令如下，

```

data a ;
  retain seed1 345678921;
  do i=1 to 100;
    x=sqrt(1)*rannor(seed1);
    output;
  end;

```

```
proc print;
run;
```

(b) 二項分佈

假如我們有一個二項分佈 $\text{Bin}(20, 0.6)$ ，也就是在 20 次試驗其成功機率為 0.6 之二項分佈，若欲產生 100 個自這個母群體產生之樣本，則可使用 `Ranbin` 其指令如下：

```
data c;
  retain seed 345678921 ;
  do i=1 to 100;
    x=ranbin(seed,20,0.6);
    output;
  end;
proc print;
run;
```

(c) 布瓦松分佈

假如我們有一個平均期望值為 1 之布瓦松分佈(Poisson distribution)，則可以使用 `Ranpoi` 之指令來產生樣本數為 100 的樣本，其指令如下：

```
data c;
  retain seed 345678921 ;
  do i=1 to 100;
    x=ranpoi(seed,2);
    output;
  end;
proc print;
run
```

SAS 處理日期及時間格式相常多，其格式見長期追蹤資料分析，在許多種方法中，有一種方法可以將非日期變項讀成日期變項，就是使用 `MDY(月,日,年)` 將變項轉成 SAS 日期變項。

(5) 字元函數

這類函數稱為 string 函數，函數包括：

`length`, `substr`, `input`, `put`, `scan`, `trim`, `Uppcase`, `Lowcase`, `||`(聯結), `index`, `idexc`, 及 `soundexc` 等。

(A) Length：欲了解 Length 函數可先使用 Proc contents 得知，以下是一實例，

SAS program：

```
data example1;
  input group $ @10 string $3.;
  left  = 'x   '; *x and 4 blanks;
  right = '   x'; *4 blanks and x;
  c1=substr(group,1,2);
  c2=repeat(group,1);
  lgroup=length(group);
  lstring=length(string);
  lleft=length(left);
  lright=length(right);
  lc1=length(c1);
  lc2=length(c2);
datalines;
abcdefgh 123
xxx      4
y        5
;
proc contents data=example1 position;
  title 'Output from PROC CONTENTS';
run;

proc print data=example1 noobs;
  title 'Listing of Example 1';
run;
```

在 proc content 中其 LEN 表示 SAS 用來儲存這個變項的 bytes 其數值內定為 8 bytes，而字元則視 input 指令中其宣告長度為何，若沒有宣告則內定長度為 8，若利用 informat 宣告，則長度視其宣告之長度，例如上述 Sting 其長度經由 Informat 宣告為 3，而 left 及 right 則視其 argument 為何。

(B) Substr(char_var,start,length)：用來截取字元項中部份長度，例 c2 代表自 group 變項第 1 個位置起截取變項之長度故此例中 c2 之 length 為 8。

(C) Repeat：重覆這個變項數次，而因為 SAS 並不知道到底資料重覆幾次，所以設定長度為 SAS 字元之最大極限 200。

我們也可以使用 year,month 及 day 等函數來截取年,月及日之資料。

(D) Intck 及 Intnx 指令：這兩個指令在求取兩個時間日期之間隔相當有用，Intck 是計算兩個時間間隔之長短。

Intck(interval,start,end)

start：開始日期

end：結束日期

例如：欲求取病人由住院日至今天之間隔

Num=Intck('N',start,Today())

Intnx 剛好和 Intck 相反，知道 interval 和 starting date 反相 end date。

(E) Lag 及 DLF 函數：Lag 函數是用來產生目前這筆資料，某些變項其上一筆(lag(1))或前幾筆(lag(n))資料之函數。

例如：每個 subject 我們有 2 次測量值，而我們欲求此次與上次資料之差距，可以使用 Lag 函數，其 SAS program 如下：

```
data lageg;
  set orig;
  ***Note: Data Set ORIG is Sorted by subj and TIME;
  diff=x-lag(x);
  if time=2 then output;
run;
```

(F) Compel：將一個變項中多個 blank(如姓名，地址)變成一個 blank，例如下列有關姓名和地址的 program：

```
data example2;
  input #1  @1  name      $20.
        #2  @1  address   $30.
        #3  @1  city      $15.
           @20 state      $2.
           @25 zip        $5.
  name=compbl(name);
  address=compbl(address);
  city=compbl(city);
```

```
datalines;  
RON CODY  
89 LAZY BROOK ROAD  
FLEMINGTON NJ 08822  
BILL BROWN  
28 CATHY STREET  
NORTH CITY NY 11518
```

```
;
```

```
proc print data=example2;  
  title 'Example 2';  
  id name;  
  var address city state zip;  
run;
```

(G) Compress：將字元中空白括弧或某些字元除掉，

compress(phone,'(-)')，將電話中'-'去掉。

(H) Verify：用來確定只有某些字元出現，其語法如下：

新變項：Verify(變項,'ABCDE')。

第三部份

統計步驟 (Proc Step)

此部份主要是統計資料分析之部份，其指令完全視所欲分析之主題，由簡單描述統計至複雜分析統計皆有，以下僅列常用之方法。

1. 列印資料

```
Proc Print;
```

2. 次數分配(Frequency)及聯列表(Contingency Table)

```
Proc Freq;
```

```
Table 變項名稱;
```

```
run;
```

以 AIDS 假想資料為例

```
libname x 'c:\yenmf\temp';  
data a;  
    set x.a433;  
proc freq;  
    table riskfact;  
run;
```

RISKFACT	Frequency	Percent	Cumulative	Cumulative
			Frequency	Percent
1	11	2.5	11	2.5
2	1	0.2	12	2.8
4	3	0.7	15	3.5
5	2	0.5	17	3.9
6	117	27.0	134	30.9
7	78	18.0	212	49.0
8	171	39.5	383	88.5
9	50	11.5	433	100.0

3. 一般描述性統計值，包括平均值、中位數、標準差、常態分佈、檢定值、P

位分數

```
Proc Univariate;
```

```
Var 變項名稱;
```

```
run;
```

以 CD4 假想資料為例

```
libname x 'c:\yenmf\temp';  
data a;  
  set x.a433;  
proc univariate;  
  var cd4;  
run;
```

結果如下：

Variable=NCD41

Moments

N	433	Sum Wgts	433
Mean	316.1501	Sum	136893
Std Dev	238.2911	Variance	56782.64
Skewness	1.024325	Kurtosis	1.673104
USS	67808839	CSS	24530101
CV	75.37277	Std Mean	11.45154
T:Mean=0	27.60765	Pr> T	0.0001
Num ^= 0	433	Num > 0	433
M(Sign)	216.5	Pr>= M	0.0001
Sgn Rank	46980.5	Pr>= S	0.0001

Quantiles(Def=5)

100% Max	1420	99%	1020
75% Q3	460	95%	750
50% Med	300	90%	610
25% Q1	130	10%	36
0% Min	1	5%	17
		1%	5
Range	1419		
Q3-Q1	330		
Mode	330		

Extremes

Lowest	Obs	Highest	Obs
1 (	264)	1020 (	292)
3 (	158)	1039 (	209)
3 (	65)	1240 (	321)
4 (	2)	1340 (	331)
5 (	298)	1420 (	341)

4. T-test

(1) Independent t test

Proc ttest;

Class 變項名稱;

Var 變項名稱;

run;

(2) Pair t test

Proc mean;

Var d;

run;

以流行性感冒為例

以 1961 年 Heasman 及 Reid 等人之流行性感冒研究為例說明 2×2

Table 於統計上之應用，此研究之主要目的是檢視家戶擁擠程度

(Crowded)是否和感染流行性感冒人數有關，其資料如下，

擁擠程度	家戶感染流行性感冒個數				
	1	2	3	4	5
Overcrowded	112 (115.3)	35 (35.7)	17 (16.4)	11 (9.8)	6 (3.8)
Crowded	155 (153.5)	41 (47.5)	24 (21.8)	15 (13.1)	6 (5.1)
Unrowded	156 (154.2)	55 (47.7)	19 (21.9)	10 (13.1)	2 (5.1)

$$\chi^2_{(8)} = 7.25, P=0.51$$

Data xx;

input group \$ x @@;

cards;

T 20 T 25 T 23 T 27 C 30 C 40 C 42 C 35

;

run;

proc ttest;

class group;

var x;

run;

結果如下：

TTEST PROCEDURE

Variable: X

GROUP	N	Mean	Std Dev	Std Error
C	4	36.75000000	5.37742193	2.68871097
T	4	23.75000000	2.98607881	1.49303941

Variances	T	DF	Prob> T
Unequal	4.2270	4.7	0.0099
Equal	4.2270	6.0	0.0055

For H0: Variances are equal, F' = 3.24 DF = (3,3) Prob>F' = 0.3597

```
data xx;
  input id x1 x2;

  dif=x2-x1;
  cards;
  1 20 30
  2 25 40
  3 23 42
  4 27 35
;
proc means menas stderr t prt;
  var dif;
run;
```

結果如下：

Analysis Variable : DIF

Mean	Std Error	T	Prob> T
13.0000000	2.4832774	5.2350172	0.0136

5. 簡單迴歸及複迴歸分析

```
Proc reg;
```

```
Model  $y = x_1 x_2 x_3 \dots$ ;
```

```
run;
```

以傷寒及副傷寒為例，以下是臺灣地區自民國 49 年至 79 年其傷及副傷寒個案及人口數，其程式如下，

```
Data a;
```

```
input year case py; /* year是年代，case是傷寒及副傷寒個案 */
```

```
id=case*10000000/py; /*py是人口數 */
```

```
lid=log(id);
```

```
t=year-64;
```

```
logt=log(year);
```

```
t2=t*t;
```

```
cards;
```

```
49 127 10792242
```

```
50 119 11151530
```

```
51 55 11527924
```

```
52 86 11902828
```

```
53 101 12280557
```

```
54 67 12654323
```

```
55 60 13021215
```

```
56 60 13362735
```

```
57 177 13682588
```

```
58 135 14096294
```

```
59 79 14505414
```

```
60 74 14835394
```

```
61 65 15141935
```

```
62 75 15426939
```

```
63 93 15708527
```

```
64 77 16000963
```

```
65 130 16328946
```

```

66 96 16660658
67 70 16974421
68 65 17307514
69 159 17642192
70 76 17970288
71 166 18296715
72 179 18595431
73 122 18872725
74 128 19135283
75 71 19356331
76 81 19563611
77 99 19788212
78 105 20005626
79 81 20233422
;
run;
proc reg;
  model lid=logt;
run;

```

結果如下：

Model: MODEL1

Dependent Variable: LID

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Prob>F
Model	1	0.51601	0.51601	4.377	0.0453
Error	29	3.41855	0.11788		
C Total	30	3.93456			
Root MSE	0.34334	R-square	0.1311		
Dep Mean	4.09305	Adj R-sq	0.1012		
C.V.	8.38832				

Parameter Estimates

Variable	DF	Parameter Estimate	Standard Error	T for H0: Parameter=0	Prob > T
INTERCEP	1	7.870217	1.80638531	4.357	0.0002
LOGT	1	-0.910394	0.43513090	-2.092	0.0453

6. 對數迴歸分析(Logistic Regression)

對數迴歸通常是用於探討其依變項是二分變項(binary variable)之迴歸方程式，表示如下，

$$\text{logit}(P) = \log \frac{P}{1-P} = \alpha + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + E \quad \text{—————(1)}$$

其中 P 代表院內感染率

$X_1, X_2, \dots, X_k$ 代表與院內感染相關之因子，如感染部份、科別等

$\beta_1, \beta_2, \dots, \beta_k$ 是其相對應之迴歸係數

通常對數迴歸方程式可以用來求下列之值

- (1) 可以用來比較不同科別之間其院內感染之相對大小(如果以對比值 OR 來表示)

$$\hat{OR}_k = \exp(\beta_k)$$

- (2) 可以用來判斷是否院內感染人員所考慮之因子和院內感染有相關

- (3) 可以用來預測病人在某種情況下(如不同科別、不同部份)其感染機率為何，

可以提供院內感染做為管理院內感染之參考。

例：

某醫院其某月份之外科、內科、加護病房及腫瘤部位其不同部位之感染人次及出院總人數敘述如下，

科別	出院總人數	感染人數(依感染部位)					感染率
		傷口	尿路	呼吸道	血流	其他	
外科	908	10	8	3	12	1	37.4%
內科	698	0	16	4	28	4	74.5%
加護病房	115	1	11	4	17	6	95.6%
腫瘤	408	1	1	1	3	0	47.5%

求 (1) 預測加護病房，其因血流而導致院內感染之機率為何?(4.4%)

(2) 尿路/其他(OR_1)、血流/其他(OR_2)及呼吸/其他(OR_3)，在控制了科別之下

其得院內感染之相對危險性為何?($\hat{OR}_1 = 3.2(95\%CI:1.87-5.37)$,

$\hat{OR}_2 = 5.36(95\%CI:3.30-8.69)$, $\hat{OR}_3 = 1.04(95\%CI:0.52-2.10)$)

(3) 在調整了感染部位、四個科別之間其院內感染差別統計上是否達顯著意義?

內科/外科($\hat{OR}_1 = 2.01(95\%CI:1.30-3.11)$)

加護/外科($\hat{OR}_2 = 2.60(95\%CI:1.63-4.14)$)

腫瘤/外科($\hat{OR}_3 = 1.40(95\%CI:0.58-3.36)$)

以下是 SAS 的程式：

Data a;

```

input ward tot n c ;      /* ward 1:外科      */
cards;                    /*      2:內科      */
1  908 10  1             /*      3:加護病房  */
1  908  8  2             /*      4:腫瘤部    */
1  908  3  3             /* tot:總出院人數  */
1  908 12  4             /*      n:院內感染人數 */
1  908  1  5             /*      c:感染部位 1:傷口 */
2  698  0  1             /*                  2:尿路 */
2  698 16  2             /*                  3:呼吸道 */
2  698  4  3             /*                  4:血流 */
2  698 28  4             /*                  5:其他 */
2  698  4  5
3  408  1  1
3  408 11  2
3  408  4  3
3  408 17  4
3  408  6  5
4  115  1  1
4  115  1  2
4  115  1  3
4  115  3  4
4  115  0  5
;
run;

data b;
  set a;

  c2=0;      /* 虛擬變項(Dummy Variables) */
  c3=0;
  c4=0;

  if c=2 then c2=1; /* 尿路 */
  if c=3 then c3=1; /* 呼吸道 */
  if c=4 then c4=1; /* 血流 */

  w1=0;      /* 虛擬變項(Dummy Variables) */
  w2=0;

```

```

w3=0;

if ward=2 then w1=1; /* 内科 */
if ward=3 then w2=1; /* 加護病房 */
if ward=4 then w3=1; /* 腫瘤 */

run;
proc logistic ;
  model n/tot=c2 c3 c4 w1 w2 w3 /r1 lackfit ;
    /* n/tot : 感染率 */
  output out=probs predicted=phat;
run;
proc print data=probs;
run;

```

結果如下：

The LOGISTIC Procedure

Data Set: WORK.B

Response Variable (Events): N

Response Variable (Trials): TOT

Number of Observations: 20

Link Function: Logit

Response Profile

Ordered Binary		
Value	Outcome	Count
1	EVENT	131
2	NO EVENT	10514

Model Fitting Information and Testing Global Null Hypothesis BETA=0

Criterion	Intercept Intercept and Only Covariates		Chi-Square for Covariates
AIC	1414.565	1341.131	.
SC	1421.838	1392.041	.
-2 LOG L	1412.565	1327.131	85.434 with 6 DF (p=0.0001)
Score	.	.	90.904 with 6 DF (p=0.0001)

Analysis of Maximum Likelihood Estimates

Variable		Parameter	Standard	Wald	Pr >	Standardized	Odds
DF	Ratio	Estimate	Error	Chi-Square	Chi-Square	Estimate	
INTERCPT 1		-5.7219	0.2568	496.5662	0.0001	.	.
C2 1		1.1545	0.2685	18.4928	0.0001	0.254612	3.172
C3 1		0.0428	0.3572	0.0144	0.9046	0.009446	1.044
C4 1		1.6785	0.2469	46.2090	0.0001	0.370177	5.357
W1 1		0.6996	0.2224	9.8989	0.0017	0.181070	2.013
W2 1		0.9555	0.2370	16.2527	0.0001	0.207360	2.600
W3 1		0.3363	0.4463	0.5680	0.4510	0.041920	1.400

The LOGISTIC Procedure

Association of Predicted Probabilities and Observed Responses

Concordant = 67.4%	Somers' D = 0.441
Discordant = 23.3%	Gamma = 0.486
Tied = 9.3%	Tau-a = 0.011
(1377334 pairs)	c = 0.720

Conditional Odds Ratios and 95% Confidence Intervals

Variable	Unit	Odds Ratio	Wald Confidence Limits	
			Lower	Upper
C2	1.0000	3.172	1.874	5.369
C3	1.0000	1.044	0.518	2.102
C4	1.0000	5.357	3.302	8.692
W1	1.0000	2.013	1.302	3.112
W2	1.0000	2.600	1.634	4.137
W3	1.0000	1.400	0.584	3.357

Hosmer and Lemeshow Goodness-of-Fit Test

Group	Total	EVENT		NO EVENT	
		Observed	Expected	Observed	Expected
1	1816	11	5.93	1805	1810.07
2	1138	4	4.14	1134	1133.86
3	1511	5	9.69	1506	1501.31
4	698	4	4.77	694	693.23
5	1224	11	10.48	1213	1213.52
6	1023	9	10.98	1014	1012.02
7	908	12	15.65	896	892.35
8	1221	30	27.78	1191	1193.22
9	1106	45	41.59	1061	1064.41

Goodness-of-fit Statistic = 8.4967 with 7 DF (p=0.2908)

OBS	WARD	TOT	N	C	C2	C3	C4	W1	W2	W3	PHAT
1	1	908	10	1	0	0	0	0	0	0	0.003263
2	1	908	8	2	1	0	0	0	0	0	0.010278
3	1	908	3	3	0	1	0	0	0	0	0.003405
4	1	908	12	4	0	0	1	0	0	0	0.017236
5	1	908	1	5	0	0	0	0	0	0	0.003263
6	2	698	0	1	0	0	0	1	0	0	0.006546
7	2	698	16	2	1	0	0	1	0	0	0.020476
8	2	698	4	3	0	1	0	1	0	0	0.006831
9	2	698	28	4	0	0	1	1	0	0	0.034099
10	2	698	4	5	0	0	0	1	0	0	0.006546
11	3	408	1	1	0	0	0	0	1	0	0.008440
12	3	408	11	2	1	0	0	0	1	0	0.026292
13	3	408	4	3	0	1	0	0	1	0	0.008806
14	3	408	17	4	0	0	1	0	1	0	0.043611
15	3	408	6	5	0	0	0	0	1	0	0.008440
16	4	115	1	1	0	0	0	0	0	1	0.004562
17	4	115	1	2	1	0	0	0	0	1	0.014329
18	4	115	1	3	0	1	0	0	0	1	0.004760
19	4	115	3	4	0	0	1	0	0	1	0.023962
20	4	115	0	5	0	0	0	0	0	1	0.004562

Primary and Adjuvant Therapy, Prognostic Factors and Survival in 1053 Breast Cancers Diagnosed in a Trial of Mammography Screening

Laszlo Tabar¹, Hsiu-Hsi Tony Chen², Stephen W. Duffy³ and Ulla Brith Krusemo⁴

¹Mammography Department, Central Hospital, Falun, Sweden, ²Graduate Institute of Epidemiology, College of Public Health, Taiwan University, Taipei, Taiwan, ³MRC Biostatistics Unit, Cambridge, UK and ⁴Uppsala University Data Centre, Uppsala, Sweden

Background: As mammographic screening becomes more widespread, larger numbers of tumours are diagnosed while small and node negative.

Methods: We examined detection mode, tumour size, node status, histological type, therapy and outcome in 1053 breast cancers diagnosed in one county of the Swedish Two-County Trial of mammographic screening for breast cancer.

Results: Of patients undergoing total mastectomy with axillary dissection, 65% were found to be node negative. For tumours of size 1-9 mm, 95% were node negative. The major effects on survival were tumour size, node status and histological type. Primary adjuvant therapy had no significant association with survival.

Conclusions: The advent of mammography has substantially enhanced the possibilities for less radical treatment. There is an urgent need for therapeutic trials utilizing mammographic-pathological correlations to ascertain in advance which tumours can and which cannot benefit from more radical therapy.

Keywords: breast cancer — prognostic factors — breast cancer screening — therapy

INTRODUCTION

During the last two decades, therapy for breast cancer has tended toward less radical surgery and more adjuvant systematic therapy. Clinical trials have indicated that breast-conserving surgery with axillary dissection and radiotherapy is as effective as radical mastectomy for tumours less than 2 cm (1). Indeed, it has been proposed that in tumours with a favourable prognosis, systematic therapy is unnecessary (2,3).

The main reason for the change in surgical practice from routine mastectomy to breast-conserving surgery or dispensing with routine radiation therapy is the decrease in tumour size and in the proportion of tumours with lymph node involvement, which has been a feature of the era of mammography screening. The observations of Cady et al. (4) suggest that in

this era, 33% of diagnosed cancers will be *in situ* and of the invasive tumours, the median size is likely to be around 1 cm.

Although clinical trials of adjuvant systematic therapy indicate a benefit in survival terms associated with chemotherapy, it is not clear whether this benefit applies to cancers which already have a very good prognosis. In an overview of chemotherapy for 'early' breast cancer, beneficial effects were noted for both hormone and cytotoxic chemotherapy (5). The definition of early, however, included tumours of size up to 5 cm, a definition which is clearly inappropriate to the age of mammographic screening (6).

There is now overwhelming evidence that breast cancer screening with mammography reduces mortality from the disease (7). This implies that breast cancer is a progressive disease, the development of which can be arrested by screening. The substantial difference in survival by tumour attributes such as size, node status and malignancy grade (greater than can be achieved by variation in therapy) indicates that the stage at which progression is halted is crucial (8).

It has been shown that a large part of the benefit of screening is via its reduction of the rate of advanced tumours in terms of size and lymph node status (7,8). Results also indicate that intratumour heterogeneity with respect to measures of aggressive potential is a commonly observed phenomenon (9). In such cases, the more poorly differentiated component (i.e. the more aggressive) grows more rapidly than the better differenti-

Received May 19, 1999; accepted September 2, 1999

For reprints and all correspondence: Stephen W. Duffy, MRC Biostatistics Unit, Institute of Public Health, University Forvie Site, Robinson Way, Cambridge CB2 2SR, UK

Abbreviations: ASP, active study population; HCR, hormone therapy, chemotherapy and radiotherapy combination; PSP, passive study population; QM, quadrantectomy; RM, radical mastectomy; SM, sub-mastectomy; TMA, total mastectomy with axillary dissection; TMNA, total mastectomy without axillary dissection

ated (10). Thus, early detection can actually improve the overall malignancy grade of a tumour and indeed this was observed to occur in the Swedish Two-County study (8,10).

In summary, the use of mammography screening for breast cancer has established a tumour population in which there are substantial numbers of node-negative tumours, tumours of size less than 1 cm and well-differentiated or moderately differentiated cancers. In addition, certain histological types, such as tubular carcinoma, are known to have an excellent long-term prognosis (10). It has long been axiomatic that early detection confers an opportunity for use of less radical treatment as well as a reduction in mortality and indeed the use of routine adjuvant therapy has been found to be unwarranted in small, node-negative tumours (11).

The Swedish Two-County Trial is a randomized trial of mammographic screening for breast cancer, in which a substantial proportion of tumours less than 1 cm in maximum diameter were diagnosed. In this study, we propose to:

- 1 describe the treatments administered by histology, tumour size and lymph node status;
- 2 ascertain how these are associated with long term outcome; and
- 3 make some tentative suggestions about which tumours may benefit from more radical therapies and which may not.

It should be noted that this paper does not report on a therapeutic trial. The tumours we report on were diagnosed during a randomized trial of mammographic screening. To avoid confounding by treatment in this trial, it was necessary to have the same therapeutic policy throughout, depending only on the stage of the disease and not varying by arm of the screening trial. The results should, however, have implications for future therapeutic trials.

MATERIALS AND METHODS

Treatment data were available from one county (Kopparberg) of the Swedish Two-County Trial, which was a randomized breast cancer screening trial initiated in 1977. A detailed description of this study was published elsewhere (12). In Kopparberg county, a total of 1053 breast cancers were diagnosed, 694 in the invited group (active study population, ASP) and 359 in women not invited (passive study population, PSP). The average follow-up until 31 December 1994 is 14.8 years. In Kopparberg county, deaths from breast cancer were 140 among 38,589 women in the ASP and 113 among 18,582 in the PSP, respectively (RR = 0.60, 95% CI 0.46–0.77).

Basic information on cancers diagnosed include tumour size, node status, malignancy grade and histological type. Detection modes include prevalent (first screen), incidence (subsequent screen), interval cancers (cancers diagnosed between screens), cancers in refusers, cancers in the control group diagnosed before screening, cancers in the control group diagnosed at first screen (in this study, the control group was screened once at the end of the trial).

Table 1. Numbers of breast cancers (deaths/cases) cross-tabulated by primary and prophylactic adjuvant therapies for women aged 40–74 years, Kopparberg county, Swedish Two-County Trial

Primary therapy	Prophylactic
Quadrantectomy (QM) (18/203)	Radiotherapy (8/54)
	Chemotherapy (1/1)
	Hormone (3/4)
	Chemo + hormone (1/1)
	None (5/143)
Sub-mastectomy (SM) (2/5)	Radiotherapy (0/1)
	Hormone (1/1)
	None (1/3)
Total mastectomy without axillary dissection (TMNA) (13/46)	Radiotherapy (2/8)
	None (11/38)
Total mastectomy with axillary dissection (TMA) (164/693)	Radiotherapy (99/276)
	Hormone (3/9)
	Chemotherapy (1/2)
	Radio + hormone (1/1)
	None (60/405)
Radical mastectomy (RM) (7/17)	Radiotherapy (5/10)
	None (2/7)
Needle biopsy (2/4)	Radiotherapy (1/2)
	None (1/2)
None (11/13)	Chemotherapy (4/4)
	Hormone (3/4)
	Chemo + hormone (3/3)
	None (1/2)
Unknown (36/72)	Radiotherapy (0/1)
	None (36/71)

Data on primary and adjuvant therapy were collected for each subject, by filling in a treatment form, constructed by the trialist, at primary treatment and at each routine follow-up examination (follow-up examinations took place four times during the first postoperative year, three times during the second, biennially thereafter up to year five and annually thereafter). Primary therapy consisted of 203 quadrantectomies (QM), five sub-mastectomies (SM), 46 total mastectomies without axillary dissection (TMNA), 693 total mastectomies with axillary dissection (TMA), 17 radical mastectomies (RM), four needle biopsies, 13 no surgery and 72 unknown (see Table 1). Systematic adjuvant therapy was divided into two types. The first adjuvant therapy was prophylactic, administered immediately after surgery. Prophylactic adjuvant therapy included radiotherapy, chemotherapy, hormone therapy and combinations of these. The second was for therapeutic purposes. After primary and prophylactic adjuvant therapy, various adjuvant therapies (referred to as 'therapeutic adjuvant therapy' here) were given at different follow-up times

Code Book

(1) Tx11.dat (Free Format) (673 records)

Variable Name	Operational Definition of Variable
ID	Personal number
AGE	Age at randomisation
RAGE	Age at diagnosis
GP	Study/control: 1=Invited (ASP), 2=Uninvited (PSP)
HOW	How detected: 0=prior; 1=first screen; 2=later screens; 3=interval cancers; 4=refuser; 5=old lady; 6=control, before screen, 7=control, first screen
YRAND	Year of randomisation
MRAND	Month of randomisation
DRAND	Day of randomisation
YOP	Year of operation
MOP	Month of operation
DOP	Day of operation
SIZE	Size in mm
NODES	Node status: 0=Negative; 1=Positive; 2=Distant meta; 3=DCIS; -1=not recorded
GRADE	Malognancy grade: 1=grade 1; 2=grade 2; 3=grade 3; 0=DCIS; -1=not recorded
HISTO1	1=DCIS; 2=Lobular; 3=Medullary; 9=Mucinous; 10=Tubular; 11=Ductal NOS grade1; 12=Ductal NOS grade 2; 13=Ductal NOS grade 3; 14=Ductal NOS grade unspecified; 15=Apocrine; 16=Papillary; 8=Others; 17=not recorded

(2) Tx12.dat (Free Format) (380 records)

Variable Name	Operational Definition of Variable
1st Line	
ID	Personal number
AGE	Age at randomisation
RAGE	Age at diagnosis
GP	Study/control: 1=Invited (ASP), 2=Uninvited (PSP)
HOW	How detected: 0=prior; 1=first screen; 2=later screens; 3=interval cancers; 4=refuser; 5=old lady; 6=control, before screen, 7=control, first screen
YRAND	Year of randomisation
MRAND	Month of randomisation
DRAND	Day of randomisation
2nd Line	
YOP	Year of operation
MOP	Month of operation
DOP	Day of operation
SIZE	Size in mm
NODES	Node status: 0=Negative; 1=Positive; 2=Distant meta; 3=DCIS; -1=not recorded
GRADE	Malognancy grade: 1=grade 1; 2=grade 2; 3=grade 3; 0=DCIS; -1=not recorded
HISTO1	1=DCIS; 2=Lobular; 3=Medullary; 9=Mucinous; 10=Tubular; 11=Ductal NOS grade1; 12=Ductal NOS grade 2; 13=Ductal NOS grade 3; 14=Ductal NOS grade unspecified; 15=Apocrine; 16=Papillary; 8=Others; 17=not recorded

(3) Tx2.dat (Fix Format) (1053 records)

Variable Name	Column	Operational Definition of Variable
ID	1-4	Personal number
CAUSEOD	5-6	Cause of death: 1=not recorded; 2=BrCA primary; 3=BrCA present; 4=Other causes
YDEATH	7-8	Year of death
MDEATH	9-10	Month of death
DDEATH	11-12	Day of death

(4) Tx3.xls (Excel Format) (1053 records)

Variable Name	Operational Definition of Variable
ID	Personal number
RAD	Prophylactic Radiotherapy: 0=No 1=Yes
CHEMO	Prophylactic Chemotherapy: 0=No 1=Yes
HORM	Prophylactic Hormonotherapy: 0=No 1=Yes
TX	-1=Unknown 1=None 2=Quadrantectomy 3=Sub-mastectomy 4=Total mastectomy without axillary dissection 5= Total mastectomy with axillary dissection 6=Radical mastectomy 7=Needle biopsy

(5) Tx4.sd2 (SAS Format) (1053 records)

Variable Name	Operational Definition of Variable
ID	Personal number
EFTM1-EFTM25	Adjuvant Radiotherapy: 0=No 1=Yes (25 Times)
STR1-STR25	Adjuvant Chemotherapy: 0=No 1=Yes (25 Times)
CYT1-CYT25	Adjuvant Hormonotherapy: 0=No 1=Yes (25 Times)
HORM1-HORM25	Interval of follow-up (months)